PROPIEDADES PSICOMÉTRICAS DE LOS MODELOS DE MEDICIÓN DEL PENSAMIENTO CRÍTICO

Análisis comparativo de confiabilidad, validez de constructo, estructura factorial y consistencia interna para investigación empírica

1. Introducción y Marco Psicométrico General

La evaluación cuantitativa del pensamiento crítico plantea un reto de alta complejidad metodológica en la psicología cognitiva y la investigación educativa. De acuerdo con el consenso del panel Delphi de la Asociación Filosófica Americana (APA) coordinado por Facione (1990), el pensamiento crítico se define como un juicio intencional y autorregulado que integra seis habilidades cognitivas centrales (interpretación, análisis, evaluación, inferencia, explicación y autorregulación) y un conjunto de disposiciones actitudinales hacia el razonamiento reflexivo.

A nivel psicométrico, la medición del constructo ha evolucionado sustancialmente. Inicialmente dominada por instrumentos de selección múltiple enfocados en la lógica formal, la disciplina ha incorporado pruebas de respuesta abierta, formatos duales de evocación/reconocimiento y rúbricas de desempeño auténtico. Este informe sintetiza las propiedades psicométricas específicas (coeficientes de consistencia interna, confiabilidad test-retest, fiabilidad inter-evaluador, estructura factorial y validez ecológica/predictiva) de las principales pruebas utilizadas en la literatura científica.

> **Nota metodológica clave:** El análisis de consistencia interna (Alfa de Cronbach / Omega de McDonald) muestra que las pruebas de respuesta cerrada (WGCTA, CCTST) destacan en confiabilidad global masiva, mientras que los instrumentos de respuesta abierta o mixta (HCTA, PENCRISAL) ofrecen mayor validez de constructo y predictiva al capturar los mecanismos activos de producción argumentativa.

2. Pruebas Estandarizadas de Opción Múltiple y Selección Forzada

Watson-Glaser Critical Thinking Appraisal (WGCTA / WGCTA-II)

El WGCTA (Watson & Glaser, 1980, 2012, 2018) es el instrumento histórico más extendido para la evaluación del pensamiento crítico en contextos universitarios y corporativos. Estructurado en 5 subescalas (Inferencia, Reconocimiento de supuestos, Deducción, Interpretación y Evaluación de argumentos), consta de 80 ítems en su versión completa (Formas A/B/C) y 40 ítems en su versión reducida (Forma S).

- **Confiabilidad de consistencia interna:** La forma completa registra coeficientes Alfa de Cronbach entre α = 0.73 y α = 0.83 en muestras normativas anglosajonas (Watson & Glaser, 1980; DeMangione & DeAnglat, 2007). La versión corta de 40 ítems reporta α = 0.82 (DeMangione & DeAnglat, 2007). En la adaptación eslovaca reciente de la Form C (Šeboková et al., 2026; N = 264), el puntaje total alcanzó α = 0.691 y ω de McDonald = 0.846.
- **Estabilidad temporal y consistencia de subescalas:** La confiabilidad test-retest del cuestionario de 40 ítems es aceptable (r = 0.89; Watson & Glaser, 2012). Sin embargo, la consistencia interna de sus subescalas individuales registra valores notablemente bajos (α = 0.23 a 0.51; ω = 0.49 a 0.72) (Šeboková et al., 2026), lo que desaconseja el uso de puntajes independientes por subescala.

• **Estructura factorial y teoría de respuesta al ítem (TRI):** Múltiples análisis factoriales confirmatorios (Bernard et al., 2008; Hassan & Madhum, 2007; Šeboková et al., 2026) demuestran que el modelo de 5 factores independientes no ajusta adecuadamente a los datos. En su lugar, mediante análisis paralelo y modelos Rasch de TRI, se ha validado una versión unidimensional reducida de 9 ítems con excelente ajuste (RMSEA = 0.042, SRMR = 0.076, ω = 0.66 a 0.70) y correlación convergente con el Test de Reflexión Cognitiva CRT (r = 0.30 a 0.38).

California Critical Thinking Skills Test (CCTST) & Disposition Inventory (CCTDI)

Desarrollados por Peter Facione para operacionalizar la matriz teórica del Informe Delphi de la APA:

• **CCTST (Cognitivo):** Consta de 34 ítems de opción múltiple que evalúan 5 dimensiones (análisis, evaluación, inferencia, deducción e inducción). Reporta coeficientes de confiabilidad global entre α = 0.78 y α = 0.80 en población universitaria (Facione, 1990; Valenzuela et al., 2014). Muestra correlaciones moderadas con pruebas de aptitud académica (SAT) y rendimiento.

• **CCTDI (Disposicional):** Cuestionario de 75 ítems en escala Likert de 6 puntos orientado a medir 7 disposiciones actitudinales (búsqueda de la verdad, mentalidad abierta, analiticidad, sistematicidad, confianza, inquisitividad y madurez cognitiva). Presenta una elevada consistencia interna global (α = 0.90), con subescalas ubicadas entre α = 0.72 y α = 0.80 (Facione, Facione & Giancarlo, 2000; Rudd, Baker & Hoover, 2000; Redhana & Wahyuni, 2021).

Cornell Critical Thinking Tests (CCTT - Nivel X y Nivel Z)

Diseñados por Robert Ennis y Jason Millman, estructurados en dos niveles diferenciados por edad:

• **Nivel X (Educación primaria avanzada y secundaria, 71 ítems):** Evalúa inducción, deducción, credibilidad de fuentes e identificación de supuestos. Registra una consistencia interna promedio mediante Kuder-Richardson KR-20 de 0.79 (Ennis & Millman, 1985).

• **Nivel Z (Estudiantes universitarios y adultos, 52 ítems):** Evalúa además falacias, definiciones y predicción. Incorpora penalización por adivinación aleatoria ('aciertos menos media falla'). Muestra una confiabilidad KR-20 de 0.67 (Ennis et al., 1985), estabilidad test-retest de r = 0.471 y α = 0.645 en estudios de educación superior (HEQCO, 2013).

3. Instrumentos de Respuesta Construida y Formato Dual (Alta Validez Ecológica)

Halpern Critical Thinking Assessment (HCTA)

Desarrollado por Diane F. Halpern (1998, 2010, 2014), el HCTA evalúa el pensamiento crítico a través de 25 escenarios cotidianos utilizando un sistema de respuesta dual que combina 25 preguntas abiertas de evocación libre (constructed response) y 25 preguntas cerradas de selección forzada (recognition) en 5 dimensiones cognitivas (razonamiento verbal, análisis de argumentos, comprobación de hipótesis, probabilidad e incertidumbre, y toma de decisiones/solución de problemas).

• **Consistencia interna global:** Presenta coeficientes Alfa de Cronbach situados entre α = 0.68 y α = 0.88 en muestras internacionales (Halpern, 2010; Marin & Halpern, 2011). Las formas estandarizadas S1 (Forma A) y S3 (Forma B) reportan α = 0.88 y α = 0.82 respectivamente (Manual HCTA, Schuhfried, 2016).

• **Fiabilidad Inter-evaluador:** Gracias a un sistema asistido por computadora con guías de codificación, la confiabilidad inter-jueces alcanza r = 0.83 para las preguntas abiertas y r = 0.93 para la puntuación total de la prueba (Manual HCTA, 2016).

• **Validez predictiva y factorial:** El HCTA es la única prueba con validez predictiva demostrada sobre comportamientos de la vida real, registrando una correlación de r = -0.38 (p < 0.001) con el *Decision Outcome Inventory (DOI)*, evidenciando que mayores puntajes en HCTA predicen una menor toma de decisiones irreflexivas y menos eventos negativos cotidianos (Butler, 2012). Análisis factoriales confirmativos respaldan una estructura de dos factores de segundo orden correlacionados (Evocación vs. Reconocimiento; r = 0.49 a 0.93), demostrando que la evocación libre aporta validez incremental sobre la selección forzada.

Prueba PENCRISAL (Pensamiento Crítico en Situaciones Cotidianas)

Desarrollada en España por Carlos Saiz y Silvia F. Rivas (2008, 2012), la prueba PENCRISAL es el estándar hispanohablante de respuesta abierta de producción pura. Consta de 35 situaciones-problema de la vida cotidiana organizadas en 5 factores procesales (Razonamiento Deductivo, Inductivo, Práctico, Toma de Decisiones y Solución de Problemas, con 7 ítems cada uno). La escala se cualifica mediante rúbrica cuantificada de 0 a 2 puntos por ítem (rango total de 0 a 70 puntos).

• **Propiedades psicométricas:** Registra una consistencia interna mediante Alfa de Cronbach entre $\alpha = 0.632$ y $\alpha = 0.83$ en muestras normativas españolas y latinoamericanas (Rivas & Saiz, 2012; Bejarano et al., 2013).

• **Validez factorial y divergente:** Sus 5 factores explican el 60% de la varianza total acumulada (Saiz & Rivas, 2008; Rivas, Morales & Saiz, 2014). Muestra una elevada validez divergente frente a pruebas de inteligencia general como el Test de Aptitudes Mentales Primarias (PMA), confirmando que evalúa procesos de pensamiento estratégico no reducibles al CI tradicional.

4. Evaluación Auténtica Curricular: Rúbrica VALUE de la AAC&U;

Para entornos educativos donde se requiere evaluar trabajos auténticos de los estudiantes (portafolios, ensayos, proyectos de grado), la Association of American Colleges and Universities (AAC&U;) desarrolló la rúbrica *Valid Assessment of Learning in Undergraduate Education (VALUE)* basada en el modelo de Paul & Elder (2007, 2019).

La rúbrica evalúa 5 dimensiones procesales (Definición del problema, Selección de evidencia, Análisis de contexto y supuestos, Postura propia y Conclusiones e implicaciones) a través de 4 niveles progresivos (1: Benchmark, 2-3: Milestones, 4: Capstone). En estudios de validación con evaluadores docentes entrenados (HEQCO, 2013), la fiabilidad inter-evaluadores mediante el Alfa de Krippendorff alcanzó coeficientes altamente rigurosos de $\alpha = 0.932$ y $\alpha = 0.974$, garantizando una elevada consistencia en la calificación cualitativa.

5. Matriz Comparativa de Propiedades Psicométricas

Prueba / Modelo	Formato y Ítems	Confiabilidad (Consistencia Interna / Test-Retest)	Validez y Estructura Factorial	Ventajas / Limitaciones
WGCTA (Watson-Glaser)	Opción múltiple. Forma C: 80 ítems. Forma S: 40 ítems.	α = 0.73 - 0.83 (80 ítems) α = 0.82 (40 ítems) r = 0.89 (Test-retest) Slovak 9-item: ω = 0.66-0.70	5 subescalas teóricas. Modelos factoriales muestran estructura unidimensional. Rasch IRT fit: RMSEA=0.042.	**Ventajas:** Baremos globales, rápida aplicación. **Lim:** Mide reconocimiento pasivo y comprensión lectora.
CCTST (California)	Opción múltiple. 34 ítems. Población universitaria.	α = 0.78 - 0.80 (Global)	Alineado al consenso APA Delphi (5 dimensiones cognitivas). Correlación moderada con SAT.	**Ventajas:** Estándar en pre/post test. **Lim:** Susceptible a adivinación aleatoria.
CCTDI (Disposicional)	Escala Likert 6 pt. 75 ítems. 7 subescalas.	α = 0.90 (Global) α = 0.72 - 0.80 (Subescalas)	Validez de contenido en 7 disposiciones actitudinales hacia el pensamiento reflexivo.	**Ventajas:** Mide el 'espíritu crítico'. **Lim:** Basado en autoinforme (deseabilidad social).
CCTT-Z (Cornell Level Z)	Opción múltiple. 52 ítems. Estudiantes y adultos.	KR-20 = 0.67 α = 0.645 (HEQCO) Test-retest r = 0.471	Evalúa inducción, deducción, credibilidad, supuestos y falacias. Penaliza adivinación.	**Ventajas:** Control de azar. **Lim:** Confiabilidad moderada; baja validez en diseño aplicado.
HCTA (Halpern)	Dual: 25 preguntas abiertas + 25 selección forzada (50 ítems total).	α = 0.68 - 0.88 (Global) Form A α=0.88, Form B α=0.82 Inter-jueces r = 0.83 - 0.93	Estructura factorial de 2º orden (Evocación/Reconocimiento). Validez predictiva sobre decisiones reales (r = -0.38, DOI).	**Ventajas:** Alta validez ecológica y predictiva real. **Lim:** Mayor tiempo y costo de corrección.
PENCRISAL (Saiz & Rivas)	Respuesta abierta de producción pura. 35 situaciones (0-70 pt).	α = 0.63 - 0.83 Consistencia interna alta en muestras hispanas.	5 factores procesales explican 60% de varianza. Alta validez divergente frente a tests de CI (PMA).	**Ventajas:** Máxima validez ecológica hispana; evalúa procesos reales. **Lim:** Requiere evaluadores expertos.
Rúbrica VALUE (AAC&U)	Cualitativa descriptiva (Rúbrica de 4 niveles) sobre trabajo auténtico.	Krippendorff α = 0.932 - 0.974 (Fiabilidad inter-evaluador entrenado).	Validez de contenido curricular en 5 dimensiones fundamentales de la educación superior.	**Ventajas:** Integrada en la enseñanza real. **Lim:** Depende de la capacitación docente.

6. Directrices y Recomendaciones para la Investigación Empírica

1. **Para estudios masivos o de tamizaje rápido:** Se recomienda el uso del *WGCTA* o *CCTST* debido a su corrección automatizada, aunque reportando únicamente la puntuación global del test y evitando interpretaciones por subescalas individuales dada su inestabilidad factorial.

2. **Para investigaciones de impacto metodológico o evaluación de programas de intervención:** Se sugiere priorizar instrumentos de respuesta abierta o mixta como el *HCTA* o el *PENCRISAL*, ya que permiten discriminar entre el conocimiento pasivo (reconocimiento) y la capacidad activa de generación argumentativa (evocación libre).

3. **Para investigaciones sobre disposiciones y motivación:** Es indispensable complementar la prueba cognitiva con inventarios validados como el *CCTDI* o la *Escala Motivacional de Pensamiento Crítico (EMPC)* de Valenzuela & Nieto, ya que la capacidad cognitiva y la motivación para pensar críticamente muestran correlaciones independientes pero complementarias.

4. **Para evaluación del aprendizaje en el aula universitaria:** La implementación de la *Rúbrica VALUE de la AAC&U* sobre tareas auténticas brinda la mayor validez ecológica y formativa dentro del currículo.